Integrantes: Paulina Budman y Sol Harari

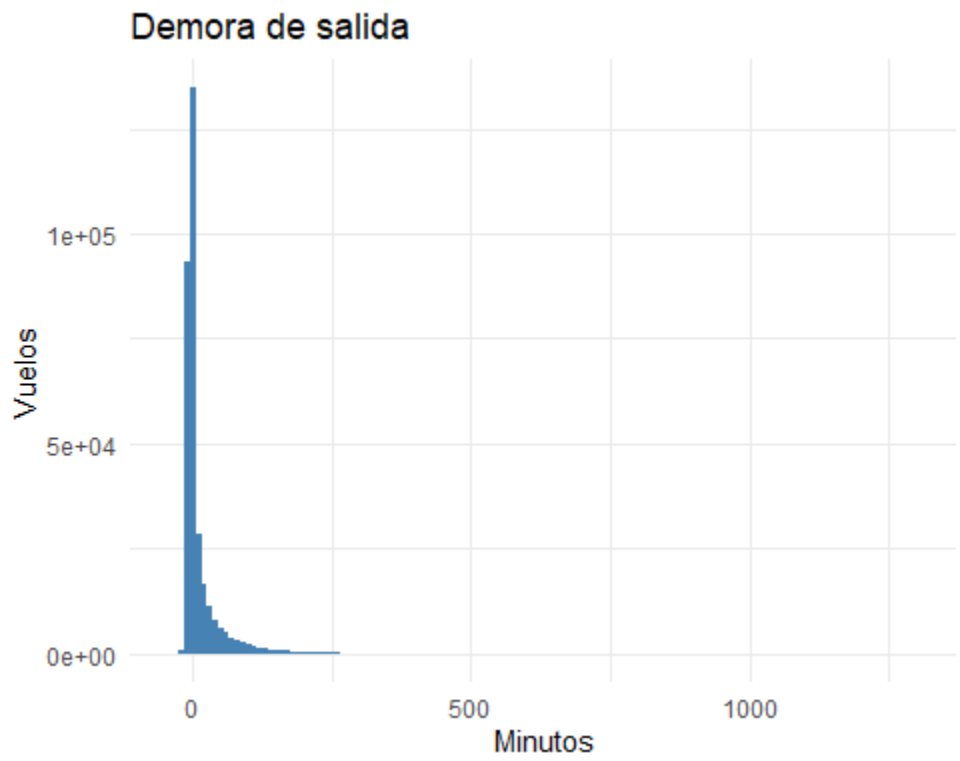
Ejercicio 1:

Introducción:

Elegimos el dataset nycflights13, que está disponible como paquete de R. Contiene información de los 336.776 vuelos que salieron de los tres aeropuertos de Nueva York (JFK, LaGuardia y Newark) durante 2013. Usamos dos de sus tablas: **flights**, con datos de cada vuelo (fecha, aerolínea, demoras, cancelaciones), y **weather**, con datos del clima por hora en cada aeropuerto (entre ellos, la velocidad del viento).

```
> nrow(vuelos)
[1] 336776
# A tibble: 1 × 3
  NA_dep_delay demora_min demora_max
         <int>      <dbl>      <dbl>
1         8255        -43       1301
```

La base tiene 336.776 vuelos. 8.255 no tienen demora registrada porque fueron cancelados, así que no los usamos al analizar demoras. La demora va de −43 minutos a 1.301 minutos.



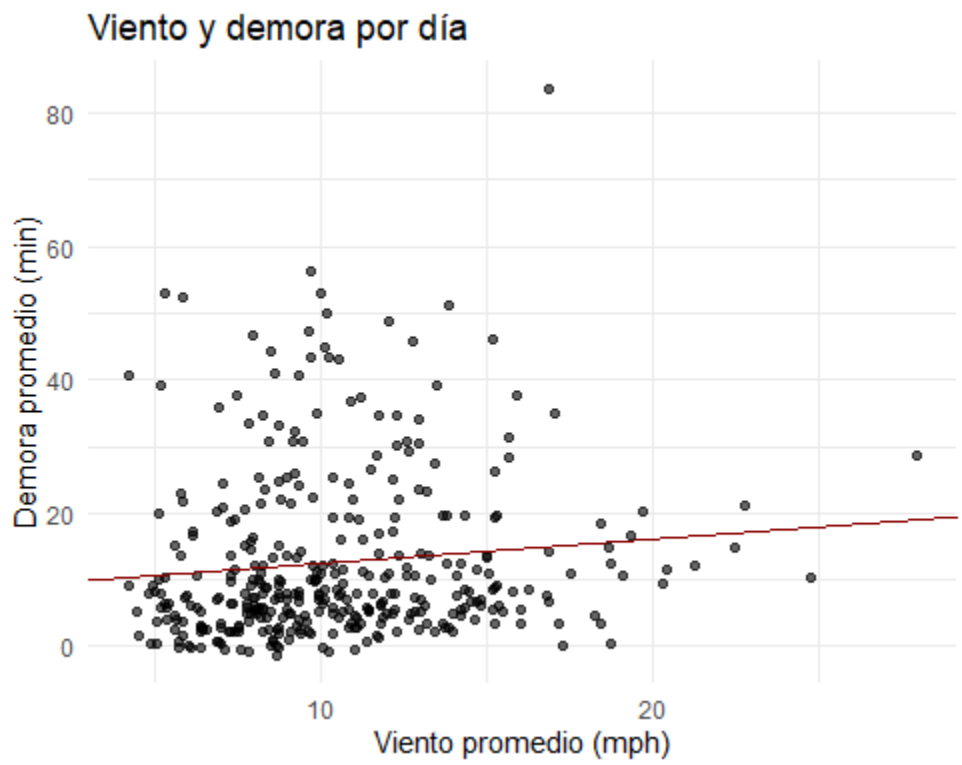
La gran mayoría de los vuelos sale a horario o con poca demora, y muy pocos tienen demoras largas.

```
# A tibble: 1 × 2
  NA_viento viento_max
      <int>      <dbl>
1         4      1048.
```

```
# A tibble: 1 × 15
  origin  year month   day  hour  temp  dewp humid wind_dir wind_speed wind_gust precip pressure
  <chr>  <int> <int> <int> <int> <dbl> <dbl> <dbl>    <dbl>      <dbl>     <dbl>  <dbl>    <dbl>
1 EWR     2013     2    12     3  39.0  27.0  61.6      260      1048.        NA      0    1008.
```

El viento máximo registrado es de 1.048 mph, un valor imposible. Lo tomamos como error de carga y por eso lo dejamos afuera de la pregunta 1.

1) ¿Dentro de un mismo mes, los días con más viento tienen más demoras en la salida?




```
(Intercept)      viento
   8.920781    0.363529
> summary(modelo)$r.squared
[1] 0.01154456
```

Mirando todos los días juntos, por cada mph más de viento la demora sube 0,36 minutos en promedio. La recta tiene pendiente positiva, pero los puntos están muy dispersos: el viento explica solo el 1% de las demoras ($R^2 = 0,01$). La relación es muy débil.

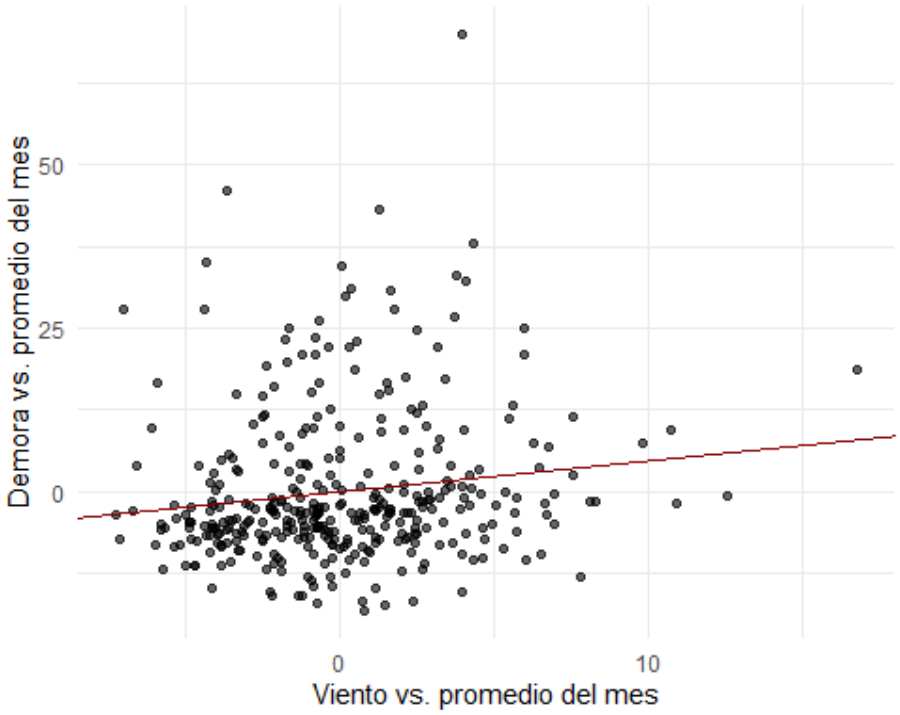
```
# A tibble: 12 x 3
   month viento demora
   <int>  <dbl>  <dbl>
 1     1  11.2   10.0
 2     2  12.2   11.1
 3     3  12.9   13.6
 4     4  11.1   13.9
 5     5   9.52  13.2
 6     6  10.3   20.9
 7     7   9.58  21.8
 8     8   8.60  12.6
 9     9   8.91   6.92
10    10   9.73   6.19
11    11  11.8    5.30
12    12  10.1   17.2
```

Los meses con más viento (febrero y marzo) no son los de más demora, y los de más demora (junio y julio) tienen poco viento. Por eso la época del año no explica la relación entre viento y demora.

```
Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) -6.983e-17  6.012e-01   0.000  1.00000
viento_mes   4.721e-01  1.714e-01   2.754  0.00618 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 11.47 on 362 degrees of freedom
Multiple R-squared:  0.02052,   Adjusted R-squared:  0.01782
```

Comparando cada día con el promedio de su mes, un día con 1 mph más de viento que lo normal tiene casi medio minuto más de demora (coeficiente 0,47). El p-valor es 0,006, así que el efecto es significativo. Igual, el viento explica muy poco de las demoras ($R^2 = 0,02$).



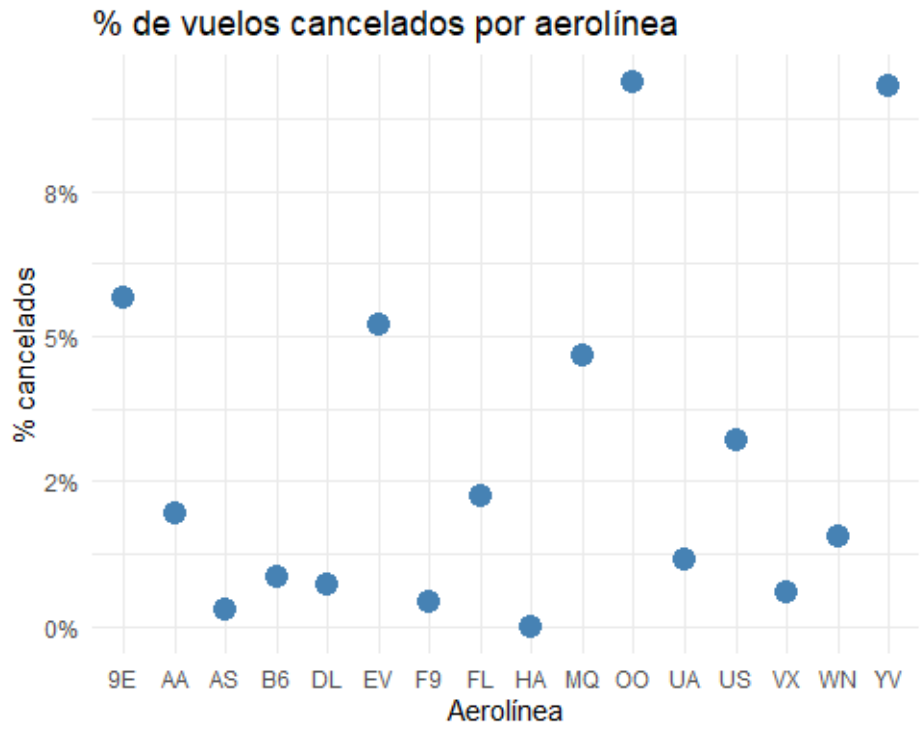
Cada punto es un día comparado con el promedio de su mes. La recta sube: los días con más viento que lo normal tienen más demora que lo normal.

Conclusión: dentro de un mismo mes, los días con más viento tienen más demoras. El efecto es significativo pero chico.

2) ¿Qué porcentaje de sus vuelos cancela cada aerolínea?

	carrier	vuelos	pct_cancelados
	<chr>	<int>	<dbl>
1	OO	32	0.0938
2	YV	601	0.0932
3	9E	18460	0.0566
4	EV	54173	0.0520
5	MQ	26397	0.0467
6	US	20536	0.0323
7	FL	3260	0.0224
8	AA	32729	0.0194
9	WN	12275	0.0156
10	UA	58665	0.0117
11	B6	54635	0.00853
12	DL	48110	0.00725
13	VX	5162	0.00601
14	F9	685	0.00438
15	AS	714	0.00280
16	HA	342	0

Las aerolíneas que más cancelan son OO y YV (9% de sus vuelos), seguidas por 9E y EV (5–6%). Las que menos cancelan son AS y F9 (menos del 0,5%) y HA, que no canceló ningún vuelo. OO tiene solo 32 vuelos en el año, así que su porcentaje es poco confiable.



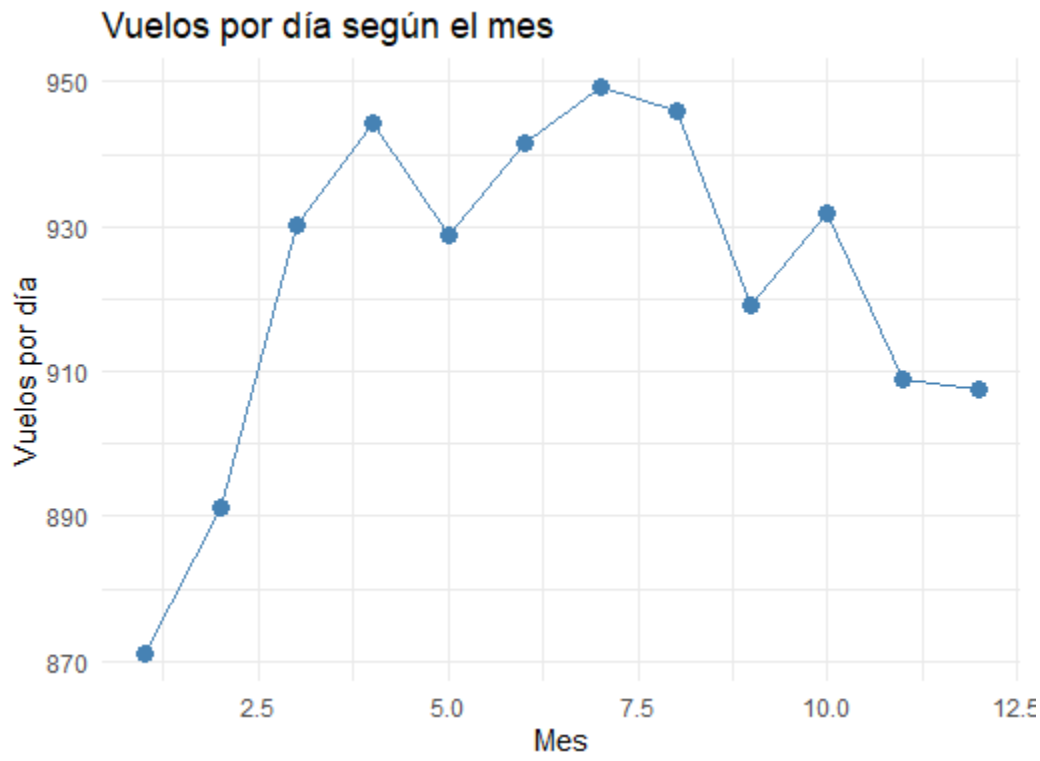
La mayoría de las aerolíneas cancela menos del 3% de sus vuelos, y solo unas pocas superan el 5%.

Conclusión: el porcentaje de cancelaciones varía mucho entre aerolíneas, de 0% a 9%.

3) ¿En qué época del año salen más vuelos?

	month	vuelos	dias	vuelos_por_dia
	<int>	<int>	<int>	<dbl>
1	7	29425	31	949.
2	8	29327	31	946.
3	4	28330	30	944.
4	6	28243	30	941.
5	10	28889	31	932.
6	3	28834	31	930.
7	5	28796	31	929.
8	9	27574	30	919.
9	11	27268	30	909.
10	12	28135	31	908.
11	2	24951	28	891.
12	1	27004	31	871.

Como los meses tienen distinta cantidad de días, comparamos vuelos por día y no el total del mes. Los meses con más vuelos por día son julio y agosto (unos 950), seguidos por abril y junio. Los de menos vuelos son enero (871) y febrero (891).



Los vuelos suben fuerte entre enero y abril, se mantienen altos durante el verano de Nueva York (junio a agosto) y bajan hacia fin de año.

Conclusión: salen más vuelos en verano y menos en invierno. La diferencia entre el mes más alto y el más bajo es de unos 80 vuelos por día (cerca de un 9%).

Ejercicio 2:

Parte 1: Ingreso por persona

Inciso 1:

```
Rows: 9843 Columns: 13
```

La base gapminder tiene 9.843 observaciones y 13 variables, con datos de distintos países a lo largo del tiempo.

```
> # Chequeos antes de graficar: NAs y rango de años
> sum(is.na(argentina$income_per_person))
[1] 0
> min(argentina$year)
[1] 1960
> max(argentina$year)
[1] 2010
```

Para Argentina hay datos de 1960 a 2010 (51 años) y ninguno falta en el ingreso por persona.



El ingreso por persona casi se duplica en el período: pasa de unos 9.800 en 1960 a unos 18.900 en 2010. Pero la tendencia no es estable. Crece hasta mediados de los 70, cae durante los 80 hasta un mínimo en 1990, se recupera en los 90, vuelve a caer con la crisis de 2001–2002 y crece fuerte después, hasta su máximo en 2010.

Inciso 2:

Introducción:

```
train  test
   41    10
```

Usamos 1960–2000 (41 años) para estimar los modelos y dejamos 2001–2010 (10 años) para testear qué tan bien predicen.

a) **Modelo lineal: income per person = β1t+ β0 + ε**

```
(Intercept)           t
11093.69686    92.94564
> summary(modelo_lineal)$r.squared
[1] 0.4512515
```

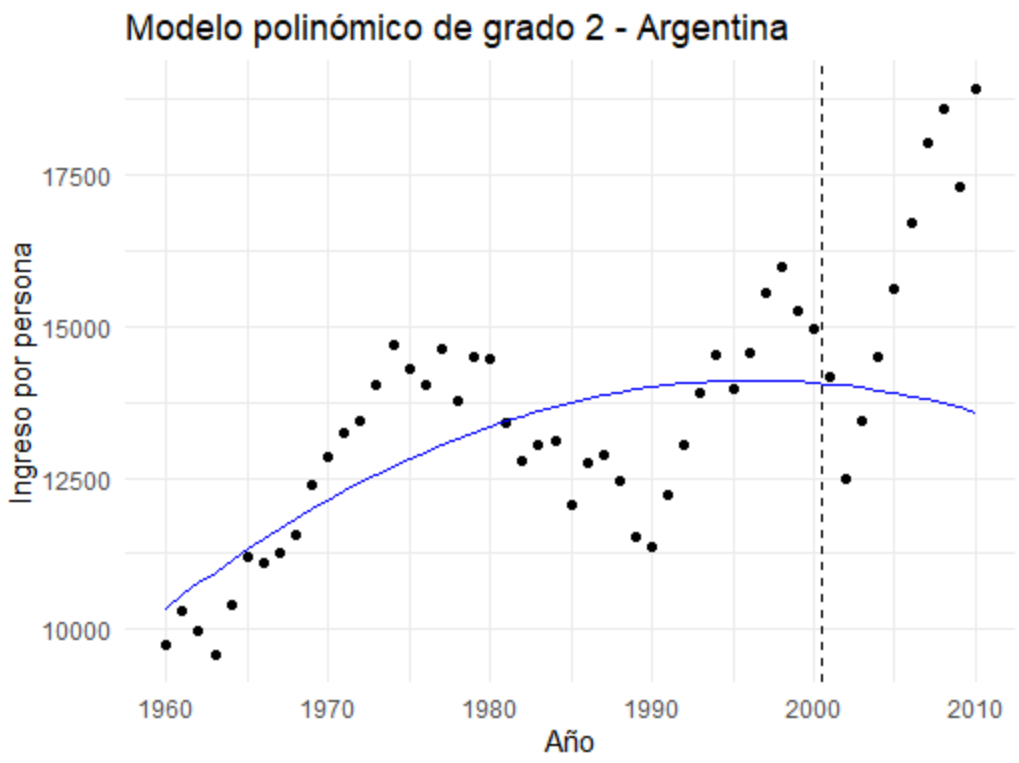
Según el modelo lineal, en 1960 (t = 0) el ingreso por persona estimado es de 11.094, y aumenta en promedio 93 por año. El tiempo explica el 45% de la variación del ingreso (R^2 = 0,45).

b) **Modelo polinómico de grado 2: income per person = β2t2 + β1t+ β0 + ε**

```
Coefficients:
                     Estimate Std. Error t value Pr(>|t|)
(Intercept)         10358.245    538.054  19.251  < 2e-16 ***
poly(t, 2, raw = TRUE)1   206.092     62.229   3.312  0.00204 **
poly(t, 2, raw = TRUE)2    -2.829      1.504  -1.881  0.06770 .
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1205 on 38 degrees of freedom
Multiple R-squared:  0.498,     Adjusted R-squared:  0.4716
```

El ingreso crece, pero cada vez más despacio (t^2 negativo). El modelo explica el 50% de la variación del ingreso (R^2 = 0,50).



La curva llega a su máximo cerca de 1996 y después baja, por eso predice una caída del ingreso en 2001–2010, cuando en realidad sube.

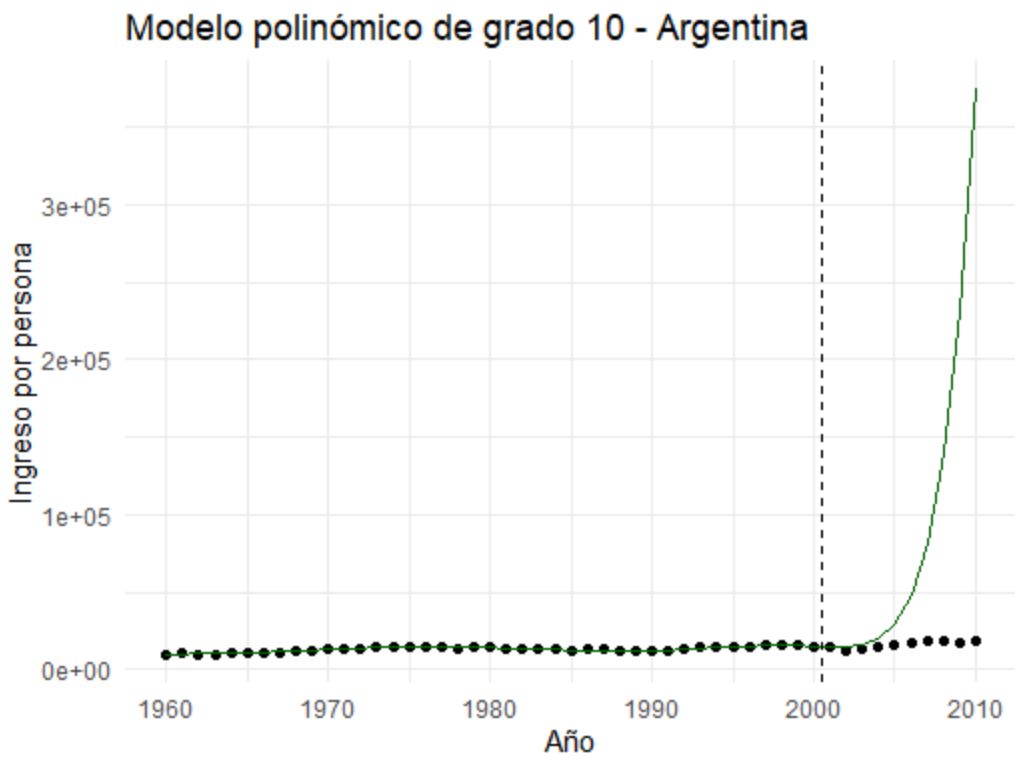
```
> rmse_train_g2
[1] 1159.965
> rmse_test_g2
[1] 3114.474
```

El error es de 1.160 en train y de 3.114 en test: el modelo se equivoca casi el triple al predecir los años que no usó para estimarse.

c) Modelo polin´omico de grado 10: income per person~β0 + β1t+ β2t2 +···+ β10t10 + ε

```
> summary(modelo_grado10)$r.squared
[1] 0.942516
```

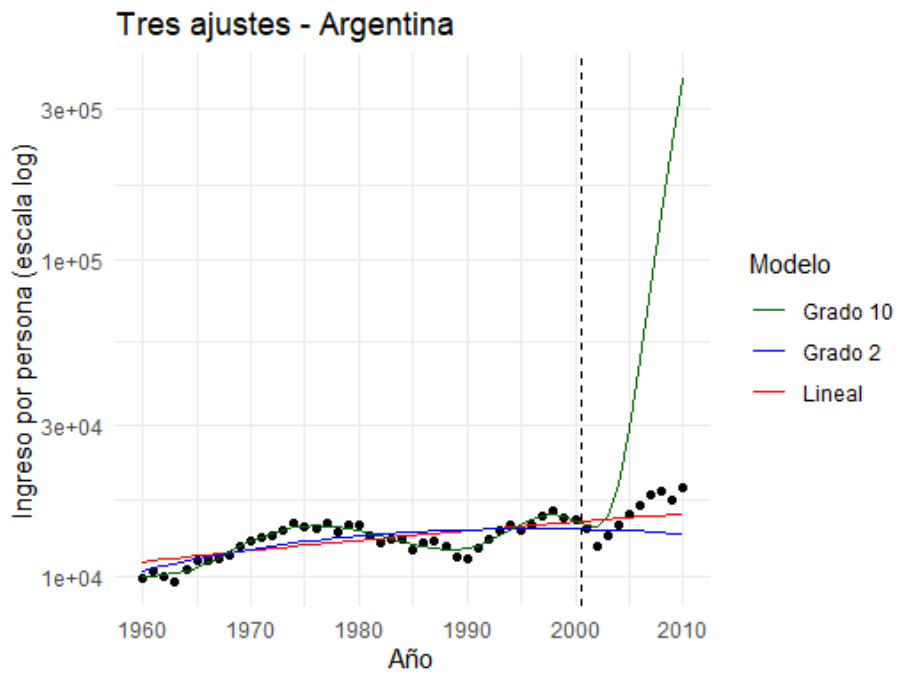
El modelo de grado 10 explica el 94% de la variación del ingreso en train (R^2 = 0,94).



La curva sigue casi perfecto los datos de entrenamiento, pero después del 2000 se dispara.

```
> rmse_train_g10
[1] 392.5158
> rmse_test_g10
[1] 138836.8
```

El error del modelo es de 393 en train (1960–2000) y de 138.837 en test (2001–2010). Predice bien los años con los que se estimó, pero muy mal los últimos 10 años.



El lineal y el grado 2 quedan cerca de los datos. El grado 10 se aleja muchísimo en el test.

```
> comparacion
    modelo rmse_train  rmse_test
1   Lineal  1212.7475   2012.472
2  Grado 2  1159.9654   3114.474
3 Grado 10   392.5158 138836.753
```

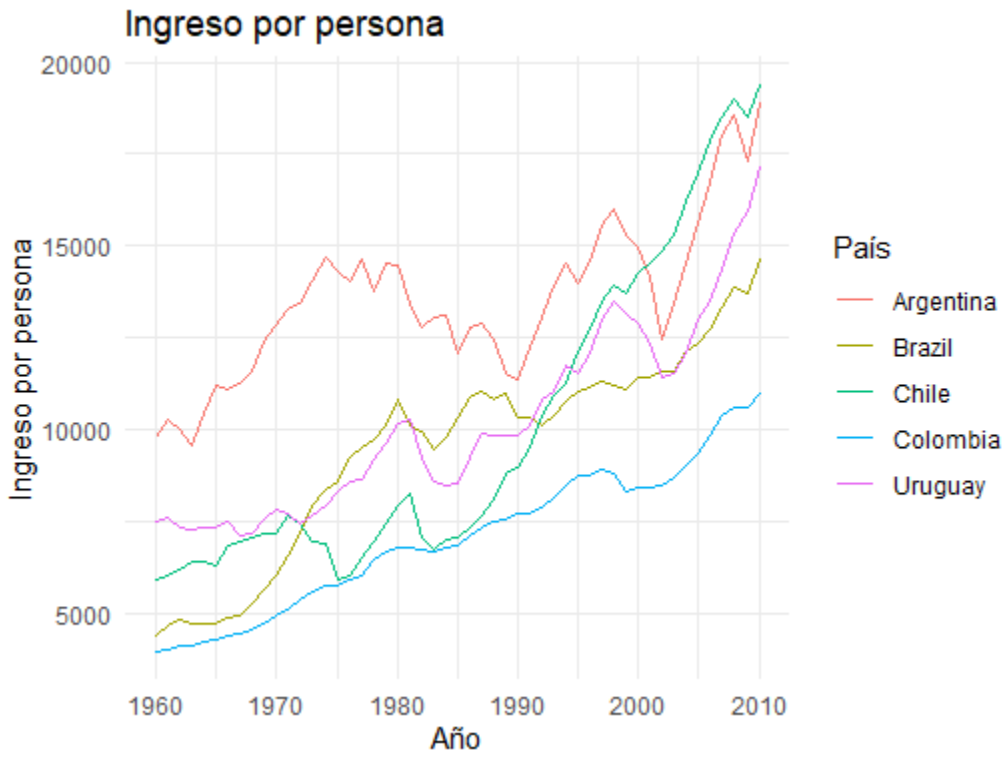
El grado 10 tiene el menor error en train, pero el mayor en test. El lineal es el que mejor predice 2001–2010.

Inciso 3:

- **a)** Una matriz de correlaciones entre los ingresos (income per person) de los cinco países.

```
> unique(ingresos$country)
[1] "Argentina" "Brazil"    "Chile"     "Colombia"  "Uruguay"
> sum(is.na(ingresos$income_per_person))
[1] 0
> ingresos %>%
+   group_by(country) %>%
+   summarise(anios = n_distinct(year), desde = min(year), hasta = max(year), .groups = "drop")
# A tibble: 5 x 4
  country   anios desde hasta
  <chr>     <int> <dbl> <dbl>
1 Argentina    51  1960  2010
2 Brazil       51  1960  2010
3 Chile        51  1960  2010
4 Colombia     51  1960  2010
5 Uruguay      51  1960  2010
```

Elegimos Argentina, Brasil, Chile, Uruguay y Colombia. Los cinco tienen datos de 1960 a 2010 (51 años) y ninguno falta, así que se pueden comparar año a año.

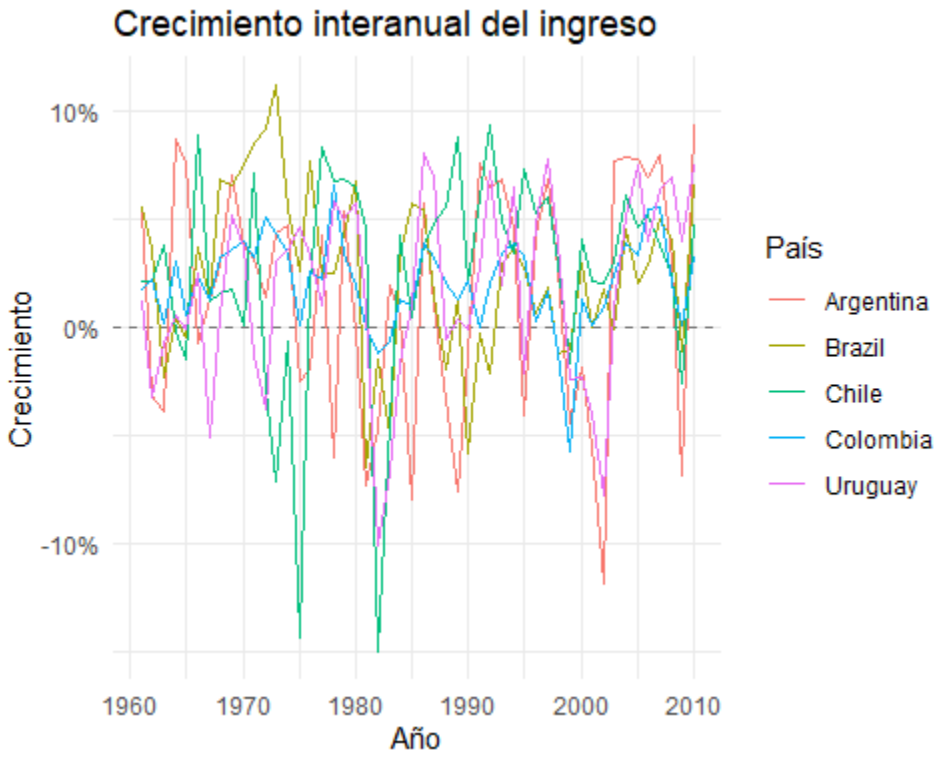


Los cinco países aumentan su ingreso por persona en el período. Argentina arranca como el más rico, pero en 2010 Chile la supera. Colombia es el de menor ingreso durante todo el período.

```
> round(cor(niveles), 2)
          Argentina Brasil Chile Uruguay Colombia
Argentina      1.00   0.80  0.77    0.83     0.81
Brasil         0.80   1.00  0.77    0.87     0.96
Chile          0.77   0.77  1.00    0.94     0.90
Uruguay        0.83   0.87  0.94    1.00     0.95
Colombia       0.81   0.96  0.90    0.95     1.00
```

Todas las correlaciones son altas (entre 0,77 y 0,96) porque los cinco países crecen a lo largo del tiempo. Argentina es la que menos se parece al resto.

b) Una matriz de correlaciones entre las variaciones porcentuales anuales (crecimiento interanual, $\Delta Y/Y$) de dichos ingresos.



El crecimiento de cada año sube y baja mucho, con años de crecimiento y años de caída en todos los países.

```
> round(cor(tasas), 2)
          Argentina Brasil Chile Uruguay Colombia
Argentina      1.00   0.27  0.17    0.51     0.40
Brasil         0.27   1.00  0.01    0.28     0.57
Chile          0.17   0.01  1.00    0.37     0.30
Uruguay        0.51   0.28  0.37    1.00     0.43
Colombia       0.40   0.57  0.30    0.43     1.00
```

Las correlaciones del crecimiento son bajas: que un país crezca mucho un año no implica que los demás también. El par más parecido es Brasil–Colombia (0,57) y el que menos, Chile–Brasil (0,01).

Conclusión: los ingresos de los cinco países crecen a lo largo del tiempo, pero año a año no necesariamente suben y bajan juntos.

Breve comentario sobre las similitudes y diferencias encontradas.

En niveles, todas las correlaciones son altas (0,77 a 0,96) porque los cinco países crecen a lo largo del tiempo. En crecimiento interanual son mucho más bajas (0,01 a 0,57), porque cada país tiene sus propias crisis y años buenos. En los dos casos, Uruguay es el país más parecido a Argentina y Chile el menos. Por eso, mirar solo los niveles exagera cuánto se parecen estas economías.

Parte 2: Esperanza de vida y género

Introducción:

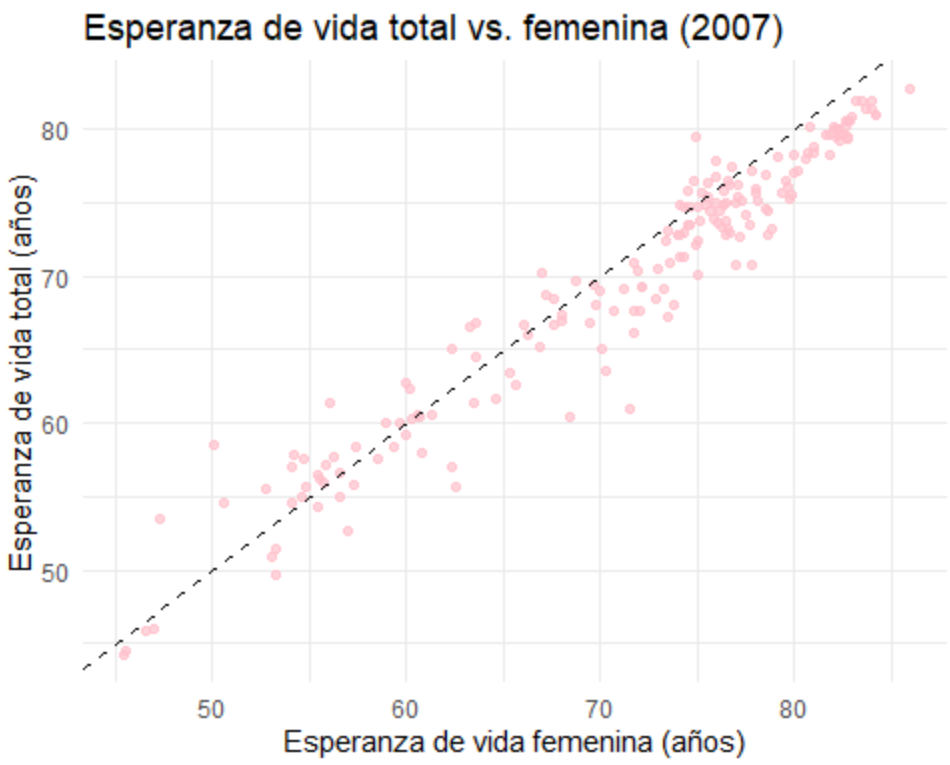
```
> # Chequeos: cantidad de paises y rango de cada variable
> nrow(gapminder_2007)
[1] 184
```

Trabajamos con el año 2007. Después de sacar los países sin dato de esperanza de vida, quedan 184 países.

```
> min(gapminder_2007$life_expectancy)
[1] 44.24
> max(gapminder_2007$life_expectancy)
[1] 82.75
> min(gapminder_2007$life_expectancy_female)
[1] 45.398
> max(gapminder_2007$life_expectancy_female)
[1] 85.913
```

La esperanza de vida total va de 44 a 83 años, y la de las mujeres de 45 a 86 años.

Inciso 5



Cada punto es un país. Donde las mujeres viven más, la esperanza de vida total también es mayor.

Inciso 6:

```
> summary(modelo_simple)

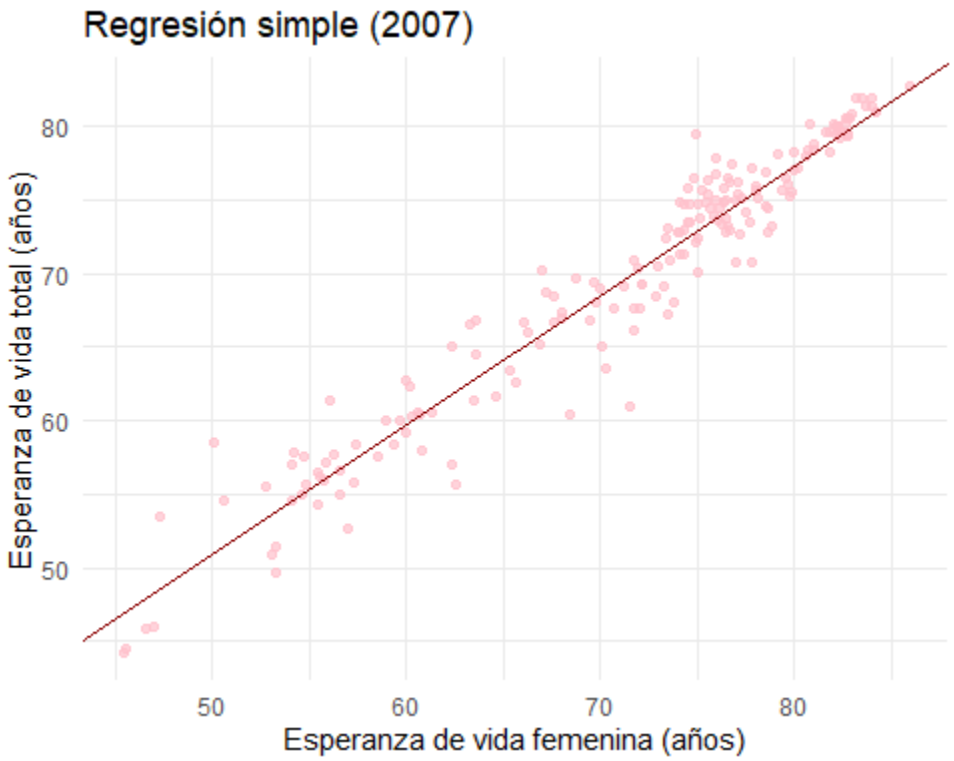
Call:
lm(formula = life_expectancy ~ life_expectancy_female, data = gapminder_2007)

Residuals:
    Min      1Q  Median      3Q     Max
-8.9689 -1.1678  0.2074  1.0814  7.4004

Coefficients:
                      Estimate Std. Error t value Pr(>|t|)
(Intercept)            6.90961    1.21507   5.687 5.08e-08 ***
life_expectancy_female 0.88147    0.01695  52.008  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.286 on 182 degrees of freedom
Multiple R-squared:  0.937,     Adjusted R-squared:  0.9366
```

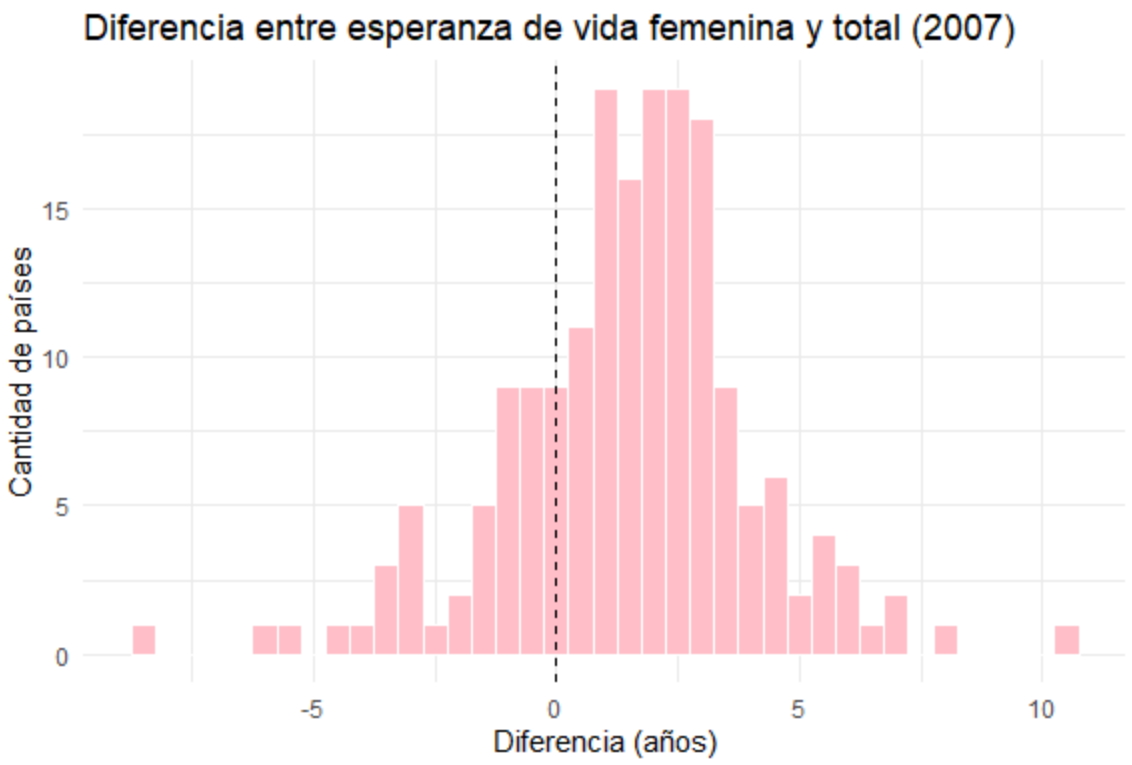
Por cada año más de esperanza de vida femenina, la esperanza de vida total sube 0,88 años en promedio. El coeficiente es muy significativo (p-valor < 2e-16). La esperanza de vida femenina explica el 94% de la variación de la esperanza de vida total ($R^2 = 0,94$).



La recta estimada pasa muy cerca de casi todos los puntos, por eso el ajuste es tan bueno.

Inciso 7:

```
# H0: life_expectancy_female = life_expectancy
# H1: life_expectancy_female > life_expectancy
```



El gráfico muestra, para cada país, la esperanza de vida femenina menos la total. Casi todas las barras están a la derecha del 0, así que en casi todos los países las mujeres viven más que el promedio de la población.

```
> n
[1] 184
> media_dif
[1] 1.505908
> t_estadistico
[1] 7.953379
>
> # Valor crítico al 5% para un test unilateral (con n grande, aprox. 1,65)
> t_estadistico > 1.65
[1] TRUE
```

En promedio, las mujeres viven 1,5 años más que el total de la población. El estadístico t es 7,95, mucho mayor que el valor crítico de 1,65 (test unilateral al 5%). Por lo tanto, rechazamos H0: la esperanza de vida femenina es significativamente mayor que la total.

Inciso 8:

```
> summary(modelo_multiple)

Call:
lm(formula = life_expectancy ~ life_expectancy_female + log(income_per_person),
    data = gapminder_2007)

Residuals:
    Min      1Q  Median      3Q     Max
-8.1105 -1.1904  0.1562  1.1833  6.6495

Coefficients:
                      Estimate Std. Error t value Pr(>|t|)
(Intercept)            5.71128    1.28205   4.455 1.47e-05 ***
life_expectancy_female 0.82870    0.02628  31.536  < 2e-16 ***
log(income_per_person) 0.54729    0.21055   2.599   0.0101 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.251 on 181 degrees of freedom
Multiple R-squared:  0.9392,    Adjusted R-squared:  0.9386
```

Ahora agregamos el ingreso por persona. La esperanza de vida femenina sigue siendo muy significativa (0,83). El ingreso también es significativo (p = 0,01): a mayor ingreso, mayor esperanza de vida total.

```
> c(R2_simple = r2_simple, R2_multiple = r2_multiple)
  R2_simple R2_multiple
  0.9369544   0.9392232
```

El R^2 casi no cambia (de 0,937 a 0,939): agregar el ingreso mejora muy poco el modelo.

Inciso 9:

```
> # Chequeos de las variables que vamos a usar
> sum(is.na(gapminder_2007$log_income))
[1] 0
> sum(is.na(gapminder_2007$child_mortality))
[1] 0
> unique(gapminder_2007$world_region)
[1] "south_asia"              "sub_saharan_africa"      "europe_central_asia"
[4] "middle_east_north_africa" "america"                 "east_asia_pacific"
```

No usamos la esperanza de vida femenina ni la masculina, porque forman parte de la esperanza de vida total y la explicarían de forma mecánica. Elegimos tres variables: el ingreso en logaritmo, la mortalidad infantil y la región del mundo. Ninguna tiene datos faltantes.

```
  R2_ingreso R2_mortalidad     R2_region
   0.6052904     0.7993822     0.8199220
```

Agregamos las variables de a una. El ingreso solo explica el 61% de la esperanza de vida. Al sumar la mortalidad infantil sube a 80%, y con la región llega a 82%.

```
> summary(modelo_propuesto)

Call:
lm(formula = life_expectancy ~ log_income + child_mortality +
    world_region, data = gapminder_2007)

Residuals:
     Min       1Q   Median       3Q      Max
-14.8168  -1.7837   0.3858   2.8264   8.6392

Coefficients:
                                  Estimate Std. Error t value Pr(>|t|)
(Intercept)                       58.97034    3.81534  15.456  < 2e-16 ***
log_income                         1.92299    0.38132   5.043 1.13e-06 ***
child_mortality                   -0.10666    0.01428  -7.467 3.66e-12 ***
world_regioneast_asia_pacific     -2.53455    1.03784  -2.442   0.0156 *
world_regioneurope_central_asia   -1.19404    0.90422  -1.321   0.1884
world_regionmiddle_east_north_africa -1.17373    1.12523  -1.043   0.2983
world_regionsouth_asia            -0.46990    1.60606  -0.293   0.7702
world_regionsub_saharan_africa    -5.23057    1.29116  -4.051 7.64e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.93 on 176 degrees of freedom
Multiple R-squared:  0.8199,    Adjusted R-squared:  0.8128
```

- **Ingreso (+1,92):** a mayor ingreso, mayor esperanza de vida.
- **Mortalidad infantil (−0,107):** a mayor mortalidad infantil, menor esperanza de vida.
- **Región (comparada con América):** África subsahariana tiene 5,2 años menos y Asia Oriental y Pacífico 2,5 años menos. Las demás regiones no son significativamente distintas de América.

El ingreso, la mortalidad infantil, África subsahariana y Asia Oriental y Pacifico son significativos ($p<0,05$). El modelo explica el 82% de la esperanza de vida ($R^2 = 0,82$).

Ejercicio Simulación 2:

Inciso 1:

La función simula una tirada de ataque del TEG. Cada jugador tira entre 1 y 3 dados, que se ordenan de mayor a menor y se comparan par a par (el más alto contra el más alto, y así). Se comparan tantos pares como dados tenga quien tira menos. En cada par pierde una ficha el perdedor, y en caso de empate gana el defensor. La función devuelve un vector con las fichas que pierde cada jugador.

Con **set.seed(123), resultado_ataque(3, 3)** da que el atacante pierde 1 ficha y el defensor 2; **resultado_ataque(3, 2)** da 2 y 0; y **resultado_ataque(1, 1)** da 1 y 0. En todos los casos, la suma de las fichas perdidas coincide con la cantidad de pares comparados (3, 2 y 1), como corresponde.

Inciso 2:

La función simula una batalla completa llamando repetidamente a **resultado_ataque**. En cada ronda el atacante tira hasta 3 dados, pero como máximo sus fichas menos 1, porque en el TEG debe dejar una ficha en su país; el defensor tira hasta 3 dados, como máximo sus fichas. Se descuentan las fichas perdidas y se repite mientras el atacante tenga más de 1 ficha y el defensor tenga al menos 1. La función devuelve las fichas finales de cada uno y un indicador de conquista (1 si el defensor se quedó sin fichas, 0 si no).

Ejemplos: **simular_batalla(5, 5)** terminó con 1 ficha para el atacante y 2 para el defensor, sin conquista; **simular_batalla(10, 3)** terminó con 8 fichas para el atacante y conquista; y **simular_batalla(2, 5)** terminó con el atacante en 1 ficha y el defensor intacto, porque con 2 fichas el atacante solo puede tirar un dado. En todos los casos, si hay conquista el defensor tiene 0 fichas, y si no la hay el atacante termina con exactamente 1.

Inciso 3:

La función simula 1000 batallas independientes con el atacante empezando con 5 fichas y el defensor con 5, y estima la probabilidad de conquista como la proporción de batallas en que el atacante se queda con el territorio. La estimación obtenida es:

$$\hat{p} = 0,189$$

Es decir, con 5 fichas contra 5, el atacante conquista el territorio en aproximadamente el **19%** de las batallas, algo menos de 1 de cada 5.

Precisión de la estimación. El error estándar es $\sqrt{(\hat{p}(1-\hat{p})/n)} = \sqrt{(0,189 \cdot 0,811 / 1000)} \approx 0,012$. Un intervalo de confianza aproximado del 95% ($\hat{p} \pm 1,96 \cdot 0,012$) es **[0,165; 0,213]**. Con 1000 batallas, entonces, la probabilidad real está en un entorno de unos 2 puntos porcentuales alrededor de la estimación.

Por qué la probabilidad es baja. Con ejércitos del mismo tamaño, el atacante parte en desventaja por dos razones:

- En el TEG el atacante debe dejar siempre una ficha en su país, así que con 5 fichas solo tiene 4 disponibles para atacar, contra las 5 del defensor.
- En caso de empate en los dados, gana el defensor.

Por eso, aunque los ejércitos sean parejos, conquistar es poco probable.

Nota. Al ser una estimación por simulación, el valor cambia si se usa otra semilla o más batallas. Con más batallas (por ejemplo, 10.000) el error estándar baja, aproximadamente a la mitad en cada cuadruplicación de las batallas.